

Media Streaming

Lecture given by Emmanuel Lochin

ISAE-SUPAERO

• Utilisation intensive de la diffusion de contenu vidéo sur Internet

• Ces diffusions sont réalisées sur un réseau best-effort

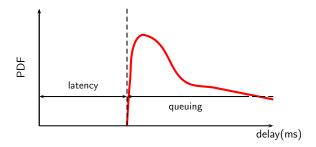
Le multimédia aujourd'hui

- ► C'est le cas pour Youtube, Netflix, Coursera, FUN, ...
- Certaines diffusions peuvent opérer sur des réseaux particuliers offrant une garantie de service
 - ► C'est le cas pour la VoD que vous achetez chez votre ISP
- Ce mode est appelé streaming. Il en existe trois classes :
 - ► stored streaming : c'est le cas des applications présentées ci-dessus
 - ▶ live streaming : lorsque les données sont produites en live (e.g. capture depuis une caméra)
 - ▶ interactive live streaming : média interactif telles la VoIP (Skype), la vidéo-conférence, ...

Lecture given by Emmanuel Lochin	Media Streaming	ISAE-SUPAERO	1/34	Lecture given by Emmanuel Lochin	Media Streaming	ISAE-SUPAERO	2/34
Stored or live-streaming				Qu'est-ce que la gigue?			

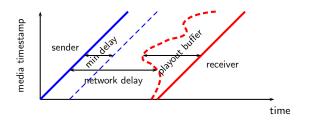
- Le stored streaming abrégé ici en streaming nécessite moins de ressources :
 - Il n'v a qu'une seule direction à considérer
 - ► Le délai impacte uniquement le démarrage → nécessite un *playout*
 - ► En revanche le streaming est sensible à la gigue (jitter) et à la capacité disponible
- Le live streaming et interactive live streaming
 - ▶ Peut opérer de façon unidirectionnelle (video live) ou bidirectionnelle (VoIP. vidéoconférence)
 - Traite des flots dits "temps-réel"
 - Sont sensibles à la gigue

- ullet Le délai du réseau est variable o c'est la gigue *jitter*
- Il correspond à la latence des messages + le délai de traversée des files d'attente



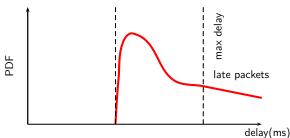
Comment minimiser la gigue? Principe du play-out buffer Le play-out buffer

- Son objectif est de minimiser la gigue en lissant le délai du réseau
- Consiste en l'implémentation d'un buffer de stockage du côté de l'application de lecture
- Sa taille impacte évidement sur le départ de la lecture du flot
- Il permet de stocker les données du flot en attente de lecture, retransmission/correction en fonction du mécanisme de fiabilité utilisé (TCP, FEC, ...)



Dimensionnement du play-out buffer Valeurs standards pour les flots intéractif

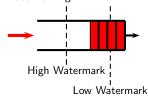
- On choisit la taille du play-out buffer en fonction d'une borne acceptable maximale de délai
- Au delà les paquets ne sont pas joués par l'application
- Cela résulte en un compromis entre délai et pertes
- Pour les applications interactives, la taille du play-out buffer est petite. On observe alors des pertes sur la vidéo ou à l'audio



- Pour la VOIP
 - ► Valeur du délai maximum tolérable 400ms
 - ► Une bonne qualité correspond à un délai inférieur à 150ms
 - ★ paquetisation applicative incluse
 - ► Tolérance aux pertes entre 1% et 10%
- Pour la vidéo
 - ► Pour garantir l'intéractivité le délai doit être inférieur à 100ms
- ullet Le délai o plus gros problème!
- Méthodologies d'évaluation des flots multimedia
 - ► Pour la VoIP : norme de l'ITU Mean Opinion Score (MOS)
 - ★ Score subjectif de qualité allant de 1 à 5
 - ► Pour la video : PSNR

Quel protocole transporte les données multimédia? RFC1889

- Du côté client, pour le stored streaming le fichier est stocké localement (au contraire d'une données live)
- Ceci permet au client d'émettre les données jusqu'à la capacité d'émission du lien
- Il peut donc y avoir débordement côté récepteur
- Pour cela les applications de lecture implémentent un type de contrôle de flot basé sur un watermarking



synchronization source (SSRC) identifier contributing source (CSRC) identifiers

▶ RTP est une sur-couche transport qui étend UDP

multimédia, les timestamp, numéro de séquences, ...

avec TCP!)

• Généralement transportée dans RTP (Real-Time Transport Protocol)

Travaille uniquement au dessus d'UDP (on ne fait pas de real-time

• RTP définit un format de paquets afin de transporter l'audio et la

► L'en-tête contient des informations sur le format des données

• Les données multimédia suivent un format standardisé : G711, H264,

RTP et QoS

Real-Time Control Protocol (RTCP)

- RTP ne fournit aucun mécanisme d'assurance de délivrance des données dans un temps donné ou tout autre garantie de QoS
- RTP est un protocole bout-en-bout : aucune prise en charge du réseau au niveau des routeurs intermédiaires
- Travaille de pair avec RTP
- RTCP correspond en quelque sorte à la voie retour
- Chaque participants transmettent périodiquement des paquets RTCP aux autres participants
- Les paquets RTCP contiennent des rapports d'émission ou réception
 - ► Statistiques utiles pour l'application : paquets émis, perdus, inter-arrivée, gigue, .
- Ces statistiques sont utilisées afin d'améliorer les performances
 - ► L'émetteur peut adapter sa transmission en fonction de ces retours

Synchronisation des flux Gestion de la capacité

- RTCP peut synchroniser différents médias au travers d'une session RTP
 - ► Audio/vidéo d'une vidéoconférence
- Pour cela RTCP utilise des timestamps
- Ces timestamps permettent de synchroniser des flux entre-eux

- Le serveur de streaming peut encoder différentes qualités audio, vidéo
- Meilleure est la qualité, plus la capacité nécessaire est grande
- Le serveur choisit la meilleure qualité à envoyer au client en fonction de la capacité réseau disponible



Quel protocole de transport pour le streaming?

Composants du media streaming

UDP

- ▶ Pour minimiser le délai des message des sessions interactives ou temps-réel
- ▶ Besoin d'un mécanisme de compensation des pertes
- TCP
 - ► Lorsque le délai (de démarrage) n'est pas essentiel
 - Retransmission des paquets perdus
 - ► HTTP/TCP passe plus facilement les firewalls

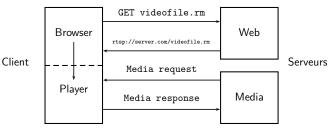
- Une session de media streaming se décompose en plusieurs parties
- Nous venons de voir qu'il était composé :
 - D'un mécanisme play-out buffer et de watermarking
 - ▶ D'un media de transport (e.g. HTTP) associé à un protocole de transport (e.g. TCP ou UDP)
- Mais il est également composé :
 - ▶ D'un mécanisme de signalisation (e.g. Real-Time Streaming Protocol -RTSP). Utiliser pour initialiser et mettre en place :
 - ★ un appel VoIP
 - une vidéo-conférence
 - ★ les paramètres de transfert de la vidéo (qualité, ...)
 - ► Les standards RTSP et HTML évolue très vite. Maintenant HTML5 inclut un video player. Devenu un standard de facto
- A noter que les contenus de media streaming sont généralement très

proches des utilisateurs et hébergés dans des CDN ou des replicats

- Agit comme un network remote controller
- Supporte les opérations suivantes :
 - ► Récupérer un média depuis un serveur
 - Gérer les invitations d'un média, par exemple, à une vidéo-conférence
 - ► Gère l'enregistrement d'une conférence
- Indépendant du protocole de transport sous-jacent
- Supporte tous les formats de description de session (SDP, XML, ...)
- Design similaire à HTTP avec différences mineures (e.g. le serveur maintient un état de session)
- Unicast et multicast

• Pour obtenir une vidéo : requête GET depuis votre navigateur web

- On obtient alors une URL du metafile correspondant à la vidéo demandée : rtsp://server.com/videofile.rm
- Le navigateur invoque alors le media player via RTSP
- La vidéo est alors transmise avec (par exemple) RTP au dessus de TCP ou UDP



Media streaming avec HTTP **Dynamic Adaptive Streaming over HTTP**

- La méthode est différente avec HTTP. C'est la méthode couramment utilisée aujourd'hui
- On récupère tout d'abord un fichier de description des données (index des clips, débits, différents encodage...) via une requête GET
- Le navigateur va alors lancer plusieurs requêtes HTTP et récupérer des segments qu'il stockera dans le playout buffer
- En fonction du taux d'occupation du buffer, le media player va sélectionner l'encodage le plus adéquat
- Les nouveaux standards tels DASH (Dynamic Adaptive Streaming over HTTP) ou HTML5 implémentent ce système
- Ils existent des versions propriétaires chez Adobe, Apple, Netflix, ...
- Problème : il n'y a aucune adaptation dynamique de l'encodage en fonction de la capacité disponible
- Solution : DASH s'adapte dynamiquement à la capacité disponible

- Du côté serveur
 - ► Divise le fichier vidéo en multiples *chunks*
 - Chaque chunks est stocké et encodé à différents taux
 - Un fichier spécial, le manifest file, fournit les URLs des différents chunks
- Du côté client
 - ► Mesure périodiquement la capacité entre le client et le serveur
 - Consulte le manifest file et demande un chunk à la fois
 - ► Choisit le bon taux d'encodage en fonction de la capacité disponible
 - ▶ Peut choisir différent taux d'encodage à différent moment de la diffusion (suivant la capacité disponible)
 - ▶ Demande le *chunk* au bon moment pour éviter famine ou saturation du buffer
 - Choisit la bonne URL localisant le chunk le plus proche du client

Lecture given by Emmanuel Lochin Media Streaming ISAE-SUPAERO 19 / 34 Lecture given by Emmanuel Lochin La VolP La VoIP Session Initiation Protocol - SIP Fonctions proposées par SIP

- ullet Protocole d'initialisation de session standardisé par l'IETF ightarrowRFC3261
- SIP est une vision sur le long terme de ce que devrait être la téléphonie sur IP
 - ► Toutes les appels téléphoniques et vidéo-conférences se feront via
 - ► Les personnes sont identifiés par des identifiants ou des adresses emails plutôt que des numéros de téléphones
 - Vous pouvez atteindre l'appelant quelque-soit sa localisation géographique et l'IP qu'il utilise à l'instant de l'appel
- Attention! SIP n'est pas Skype

- Initialise l'appel, l'ouverture et sa fermeture et négocie les paramètres d'encodage audio
- Détermine l'IP courant de l'appelé
 - ► Correspondance effectuée entre l'identifiant de l'utilisateur SIP et son adresse IP
- Gestion de l'appel
 - ► Ajout/retrait d'utilisateurs durant l'appel
 - Changement d'encodage
 - ► Transfert, mise en attente

La VolP Mécanismes réactifs de récupération des pertes ARQ Skype

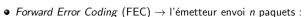
- ullet Application propriétaire o spécifications exactes non disponibles
- Skype est un réseau dit en overlay → réseau P2P
- Les clients s'enregistrent auprès d'un supernode puis la connexion des clients s'effectue
- Une communication entre deux clients Skype se trouvant sur le même réseau dialogue directement
- Lorsqu'au moins un des deux clients se trouve derrière un NAT, une connexion est maintenue avec le supernode pour que la communication fonctionne
 - ► Quel problème de sécurité voyez-vous?



- Mécanismes basés sur la retransmission, suite à la détection d'une perte par :
 - ► Acquittement, acquittement négatif : ACK, SNACK, RTO, ...
- RTO > RTT : Délai de récupération d'une perte $\geqslant \frac{3}{2} \times RTT$

Mécanismes pro-actifs de récupération des pertes Code à effacement





- k paquets sources
- ▶ n-k suivis des n-k paquets redondants
- Code "idéal" : x redondances suffisent pour x pertes
 - ► Reed Solomon
 - ► Complexité fonction de la taille du bloc
- LDPC, LT code, Raptor, ...
 - ▶ Faible complexité
 - ► Inefficace pour de petites tailles de blocs
- Taux de redondance : R = (n k)/n
- Taux de codage : k/n

Autre schéma FEC pour la VoIP : le piggybacking

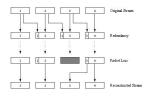
• Forward Error Coding (FEC) \rightarrow l'émetteur envoi n paquets :

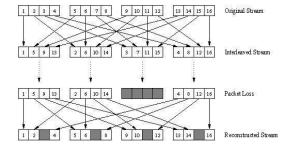
- k paquets sources
- ▶ n-k suivis des n-k paquets redondants
- Code "idéal" : x redondances suffisent pour x pertes
 - ▶ Reed Solomon
 - ► Complexité fonction de la taille du bloc
- LDPC, LT code, Raptor, ...
 - ► Faible complexité
 - ► Inefficace pour de petites tailles de blocs
- Taux de redondance : R = (n k)/n
- Taux de codage : k/n

Principe de l'entrelacement

• Principe : on piggyback un flot de qualité inférieure

- L'information redondante devient un flot audio de moindre
 - ▶ Par exemple : flot nominal en PCM 64kbps \rightarrow flot de redondance GSM 13kbps





Media Streaming

ISAE-SUPAERO 26 / 34 ecture given by Emmanuel Lochin Lecture given by Emmanuel Lochin Media Streaming Mécanismes pro-actifs de récupération des pertes En résumé

- Les flots interactifs ou "temps-réel" (i.e. sensibles au délai) utilisent UDP pour ne pas être contraint par le contrôle de congestion et les retransmissions TCP
- Peuvent utiliser un "très petit" playout buffer
- Du côté serveur : adapte l'encodage en fonction de la capacité disponible
- Mécanisme de récupération de pertes au dessus d'UDP
 - ▶ code à effacement, entrelacement, ...
 - ► retransmission si le temps le permet

- Code en bloc
 - ► la fiabilité augmente avec la taille des blocs
 - ▶ la complexité augmente avec la taille de blocs
 - ► le délai augmente avec la taille du bloc
 - ▶ efficacité dépend de la configuration (n,k)
- ARQ
 - ► fiabilité totale
 - ▶ délai de reconstruction fonction du RTT
 - ► Efficacité
 - ★ optimale si forte tolérance au délai
 - décroit fortement autrement

H-ARQ : code en block + ARQ

- Fiabilité totale et délai moyen moindre comparé à l'ARQ
- Dans les pires cas, le délai est toujours fonction du RTT

Lecture given by Emmanuel Lochir Mécanisme de fiabilité On-the-fly coding

- Objectif : disposer d'un mécanisme générique
 - ► Proche de la capacité du canal
 - Complexité abordable
- ullet Problème : deux classes d'application o contrainte de délai et fiabilité totale
 - ► Code à effacement : compromis entre délai, robustesse et complexité
 - ► Avec ARQ/H-ARQ : le délai est un multiple du RTT dans le pire cas

Solution

- Codage à fenêtre élastique
- Fiabilité totale + délai de récupération des pertes paramétrable et indépendant du RTT
- Le principe de base connu sous le nom de "on-the-fly coding" consiste à utiliser une fenêtre d'encodage incluant tout les paquets sources émis mais non accusés
- Nous présentons par la suite un mécanisme de ce type développé à l'ISAE nommé Tetrys
- Il existe des alternatives : RLNC (MIT)
- Ces codes peuvent s'intégrer à des niveaux applicatifs ou noyau
 - ► C'est le cas de RLNC avec Coded-TCP

